

# Analýza priemerných miezd v štátoch Európskej únie

Tomáš Becza

Máj 2025

## 1 Úvod

Jedným z najdôležitejších ukazateľov (aj keď nie jediným) kvality života v rôznych štátoch je nesporne priemerná mesačná mzda. V tejto práci sa zamerám na jej analýzu vo vybraných štátoch Európskej únie v roku 2015. Hlavnými cieľmi práce sú odpovedať na nasledujúce otázky:

- Aké hodnoty má sledovaná veličina? Aká je priemerná mzda naprieč EÚ? Ktoré štáty najviac vyčnievajú?
- Aké iné veličiny ovplyvňujú mzdu? Ktoré z nich majú najväčší dopad?
- Ako je možné z daných veličín aproximovať reálnu hodnotu priemernej mzdy? Je daný vzťah spoľahlivý?

## 2 Priemerná mzda

Hodnoty priemernej mzdy získam z Eurostatu, konkrétne z datasetu **nama\_10\_fte**. Ten obsahuje dáta z 26 krajín EÚ, v skúmanom roku 2015 však chýba **Spojené kráľovstvo**, ktoré vtedy ešte bolo súčasťou EÚ, a **Holandsko**, ktoré je v metadátach uvedené ako chýbajúce, každopádne bez udania dôvodu.

Dataset takisto obsahuje priemernú mzdu **EU27\_2020**, ktorá je pre 27 krajín súčasného zloženia EÚ (vrátane Holandska), táto hodnota však práve kvôli Spojenému kráľovstvu nie je priemernou mzdou EÚ v tom čase, ničmenej vo vizualizáciách ju s ňou stotožním.

V geografickej polohe môžeme nájsť aj **EA20**, ktorá je vypočítaná ako priemerná mzda pre 20 krajín súčasnej eurozóny (množine členov EÚ, ktorí používajú spoločnú menu - euro). Ani tento ukazateľ sa nezaobíde bez nepresností, keďže v skúmanom roku 2015, mala eurozóna 19 členov (**Chorvátsko** prijalo euro v roku 2023). Takisto ako vyššie, zmenu vo vizualizáciách zanedbávam.

Menou, v ktorej budem skúmať mzdy, bude euro. A keďže nie sme zvyknutý na ročnú mzdu, pre lepšie predstavenie ju prevediem na mesačnú.

### 2.1 Charakteristika priemernej mzdy


Pozrieme sa bližšie na významné štatistické miery.

| NotNA | Mean | Sd   | Min | Pctile[25] | Median | Pctile[75] | Max  | IQR  |
|-------|------|------|-----|------------|--------|------------|------|------|
| 26    | 2159 | 1347 | 531 | 1031       | 1782   | 3366       | 5116 | 2335 |

Tabuľka 1: Štatistické ukazatele priemerných mesačných plátov.


Ako vidíme v tabuľke 1, skutočne máme 26 štátov, s najmenšou priemernou mzdou 531€ a najvyššou 5116€. Čo je takmer desaťnásobok, môžeme teda očakávať že mzdy budú veľmi rozptýlené, čo do-svedčuje aj vysoká smerodatná odchýlka. Ďalej je možné vidieť, že aj priemer týchto priemerov je vyšší ako medián, čo znamená, že máme málo veľmi bohatých štátov.

### Average monthly wage in EU countries



Obr. 1: Charakteristika priemerných miezd.

### Average monthly wage in EU countries



Obr. 2: Poradie priemerných miezd.

Na histograme (Obr. 1) vidíme, akoby bola Únia rozdelená na chudobnejšiu (1000 - 2000€) a bohatšiu (3000 - 4000€) časť. Samozrejme je vidieť aj 3 štáty ktoré sú medzi týmito skupinami. Máme aj veľmi chudobné štáty (na európske pomery), ktoré majú priemernú mzdu pod 1000€, ale aj veľmi bohaté štáty nad 4000€.

Rebríček najvyšších miezd (Obr. 2) neprekvapivo otvára **Luxembursko** nasledované **Dánskom** a **Írskom**. Najnižšie mzdy sú v **Bulharsku** a **Rumunsku**. Ďalej je možné vidieť, že priemerná mzda v eurozóne je vyššia ako v celej EÚ súhrnne. Najväčšie krajiny EÚ ako **Nemecko**, **Francúzsko** a **Taliansko** ovplyvňujú celkovú priemernú mzdu výraznejšie ako ostatné štáty a teda sú aj blízko

priemeru za EÚ.

## 2.2 Faktory ovplyvňujúce priemernú mzdu


Existuje množstvo údajov, ktoré majú dané štáty odlišné. Chceme sa však zamerať na také ukazatele, ktoré by mohli mať vplyv na priemernú mzdu v štáte.

**HDP na obyvateľa** môže hrať snáď najdôležitejšiu rolu. Veľmi dôležitý ukazateľ, ktorý sa často globálne používa aj sám osebe ako numerickým vyjadrením kvality krajiny. Asi je pomerne intuitívny nápad, že kde je viac peňazí, tam sa aj viac ujde jednotlivcovi.

Z vyššieho grafu je vidno napríklad, že z prvých troch krajín používajú **euro** dve, z posledných ani jedna. Navyše priemer eurozóny je vyšší ako celej EÚ, teda je logické uvažovať aj tento vplyv. Na prijatie do eurozóny je potrebné splniť prísne ekonomické podmienky, čo teda môže znamenať, že krajine sa ekonomicky darí, tým pádom môže byť predpoklad na vyššiu mzdu oprávnený.

Veľmi často sa stretávame aj s tvrdeniami, že titul z **vysokej školy** zabezpečí osobe nadpriemerný príjem. Preto má zmysel uvažovať podiel absolventov týchto škôl v populácii krajiny. Títo absolventi sú schopní vykonávať práce s vysokými požiadavkami na znalosti, ktoré sú aspoň do istej miery odmenené.

Pozorné očko si v grafe vyššie všimne, že všetky krajiny nad európskym priemerom sa **pripojili k EÚ** ešte v minulom storočí (dokonca tisícročí). Na vstup do EÚ je potrebné tiež splniť radu požiadaviek. Členstvo v EÚ poskytuje priaznivé prostredie pre obchod a celkovo legislatívny aparát podporujúci rast miezd. Netreba zabudnúť ani na eurofondy, ktoré krajina čerpá aj na podporu zamestnania.



Obr. 3: Geografická vizualizácia priemerných miezd.

## 3 Regresory

### 3.1 HDP na obyvateľa


Dáta získam z Eurostatu, konkrétne z **tipsna40**. Dataset obsahuje údaje o hodnote HDP na obyvateľa vo vybraných európskych krajinách. Ja sa zameriam na rok 2015 a krajiny v ktorých mám priemernú mzdu.

#### 3.1.1 Charakteristika HDP na obyvateľa

| NotNA | Mean  | Sd    | Min  | Pctile[25] | Median | Pctile[75] | Max   | IQR   |
|-------|-------|-------|------|------------|--------|------------|-------|-------|
| 26    | 26936 | 19619 | 6560 | 13350      | 19735  | 37543      | 95090 | 24193 |


Tabuľka 2: Štatistické ukazatele HDP na obyvateľa.

Z tabuľky 2 vidno obrovský rozdiel medzi priemerom a mediánom, preto očakávam, že tu bude zopár skutočne odľahlých hodnôt.



Obr. 4: Charakteristika HDP na obyvateľa.

GDP per capita in EU countries




Obr. 5: Poradie HDP na obyvateľa.

Na grafe 4 je vidno, že veľká väčšina krajín má HDP na obyvateľa do 40 tisíc eur. Nad touto hranicou sa nachádzajú už len štyri krajiny.

Graf 5 je takmer identický ako graf 2 priemerných mesačných miezd. Výrazným rozdielom je ešte vytŕčajúce viac **Luxembursko**, ktoré to dosahuje hlavne kvôli svojej malej populácii.


### 3.1.2 Vzťah HDP na obyvateľa a priemernej mzdy



Obr. 6: Závislosť priemernej mzdy na HDP na obyvateľa.

Až na zopár bodov, je v grafe 6 vidno, že medzi veličinami je takmer dokonalý lineárny vzťah.

Test nulovosti Pearsonovho korelačného koeficientu na hladine  $\alpha = 5\%$  zamietol ( $p = 2 \cdot 10^{-11}$ ) nekorelovanosť v prospech hypotézy, že veličiny **sú korelované**.




Obr. 7: Geografická vizualizácia HDP na obyvateľa.


## 3.2 Mena

Dáta získam z verejne dostupných zdrojov.

### 3.2.1 Charakteristika meny a jej vplyv na platy



Obr. 8: Závislosť priemernej mzdy na mene krajiny.




Obr. 9: Poradie priemerných miezd s dôrazom na používanie eura.

Ako môžeme vidieť na grafe 8, zo sledovaných štátov platia viac ako dve tretiny eurom. Takisto je vidno, že priemerný plat v štátoch platiacich eurom je okolo tisíciky vyšší ako kde platia vlastnou

menou. Napriek malému počtu krajín používajúcich národnú menu, je rozptyl hodnôt takmer rovnaký ako s dvakrát početnejšou skupinou používajúcich euro.

Z grafu 9 je očividné, kde sa berie vysoká variácia pre štáty platiace národnou menou. Môžeme v tejto skupine nájsť dve vysoko nadpriemerné štáty, čo sa platov týka, **Dánsko**, ktoré má z povinnosti prijať euro výnimku a **Švédsko**. Ostatné štáty nepoužívajúce euro majú platy nižšie ako polovica z priemeru eurozóny. Tam je však možné nájsť aj nenulový počet krajín s eurom.

Test zhody stredných hodnôt priemerných mesačných platov, rozdelených na kategórie podľa používania eura nezamietol hypotézu ( $p = 0.24$ ), že stredné hodnoty **nie sú štatisticky významne odlišné** na hladine významnosti 5%.



Obr. 10: Eurozóna v roku 2015.

### 3.3 Vysoké školy

Dáta sú z Eurostatu a ide o dataset **edat\_lfse\_03**. Dataset obsahuje mnoho údajov o absolventoch škôl v európskych štátoch. Ja sa budem sústrediť na nami skúmané štáty v roku 2015. Ďalej ma budú zaujímať všetky pohlavia a najširšia veková skupina ktorú dataset ponúka - 15 až 64 rokov - **produktívny vek**. V tejto vekovej skupine sú uvedené percentá, koľko ľudí má absolvovaný daný typ školy. Uvažuje sa len najvyššie dosiahnuté vzdelanie.

Ďalej ma budú zaujímať len absolventi týchto úrovni vzdelania podľa štandardu **ISCED 2011**:

- **úroveň 5** - krátkodobé úspešne ukončené vysokoškolské vzdelanie,
- **úroveň 6** - bakalárske vzdelanie,
- **úroveň 7** - magisterské vzdelanie,
- **úroveň 8** - doktorandské vzdelanie,


spolu združené v kategórii **ED5-8**.

#### 3.3.1 Charakteristika úrovne vzdelania

| NotNA | Mean | Sd  | Min | Pctile[25] | Median | Pctile[75] | Max | IQR |
|-------|------|-----|-----|------------|--------|------------|-----|-----|
| 26    | 27   | 6.8 | 15  | 21         | 27     | 33         | 39  | 12  |


Tabuľka 3: Štatistické ukazatele vysokoškolského vzdelania.

Podiel absolventov vysokých škôl zobrazených v tabuľke 3 je zatiaľ najviac vyrovnaným ukazovateľom v EÚ. Priemer medzi krajinami by sme našli presne kde medián - na hodnote 27%. Polovica krajín má vysokoškolskú vzdelanosť na úrovni medzi 21 a 33 percent.



Obr. 11: Charakteristika vysokoškolského vzdelania.

## Tertiary education in EU countries




Obr. 12: Poradie podľa vysokoškolského vzdelania.

Tak ako vyššie čísla naznačovali, skutočne dáta na grafe 11 vyzerajú takmer ako z rovnomerného rozdelenia.

Najvyššie úrovne vysokoškolského vzdelania (Obr. 12) sú v **Írsku**, na **Cypre** a vo **Fínsku**. Írske a fínske školy sú celosvetovo známe pre svoju kvalitu, preto nie je prekvapením, že miestni vidia možno väčší zmysel v štúdiu ako priemerný občan EÚ. Cyprus je prekvapivým štátom, vysoký podiel môže byť zapríčinený blízkym ľudnatým Tureckom a všeobecne je najbližším EÚ štátom aj pre Blízky východ a časť Afriky. Týchto ľudí z okolia možno láka geografická blízkosť a vidina uznávaného titulu z členského štátu EÚ. Táto krajina je tiež známa nízkou daňovou záťažou a preto má veľa firiem (formálne) sídlo pre EÚ práve tu. No a je všeobecne známe, že korporáty si potrpia na vzdelanie.

Najnižšie úrovne môžeme nájsť (Obr. 12) v **Rumunsku**, **Taliansku** a na **Slovensku**. Rumunsko a Slovensko sú určite krajiny, ktoré trpia "*odlivom mozgov*". Ťažko nájsť dôvod prečo sa však nedarí Taliansku. Môže byť, že v krajine sa nie je veľký problém zamestnať bez vysokej školy a tak nie je veľmi populárnou voľbou. Je tiež známe, že napriek veľmi rozvinutému severu krajiny, na juhu možnosti zďaleka nie sú rovnaké, tento rozdiel v regiónoch sa možno práve v tejto štatistike odzrkadľuje.


### 3.3.2 Vzťah úrovne vzdelania s priemernou mzdou



Obr. 13: Závislosť priemernej mzdy na podiele vysokoškolských absolventov.

Preložiť body z grafu 13 nejakou priamkou asi veľmi zmysel nedáva. Minimálne však je vidno, že väčšinou s úrovňou vysokoškolského vzdelania rastie aj priemerný plat.

Test nulovosti **Pearsonovho** korelačného koeficientu na hladine  $\alpha = 5\%$  zamietol ( $p = 0.003$ ) nulovosť v prospech hypotézy, že veličiny **sú korelované**.



Obr. 14: Podiel absolventov vysokých škôl v populácii v produktívnom veku.

### 3.4 Dĺžka členstva v EÚ

Údaje o dĺžke členstva som získal z verejne dostupných zdrojov.


#### 3.4.1 Charakteristika dĺžky členstva

| NotNA | Mean | Sd | Min | Pctile[25] | Median | Pctile[75] | Max | IQR |
|-------|------|----|-----|------------|--------|------------|-----|-----|
| 26    | 25   | 19 | 2   | 11         | 16     | 40         | 57  | 29  |

Tabuľka 4: Štatistické ukazatele dĺžky členstva.

Podľa tabuľky 4 sú najstarší členovia (zakladajúci) sú v Únii už 57 rokov (od 1958). Najmladšie **Chorvátsko** sa pripojilo pred dvomi rokmi. Časovým obdobím, ktoré rozdeľuje Úniu na (takmer) rovnako veľké dve časti starých a nových členov je 16 rokov.

#### 3.4.2 Vzťah dĺžky členstva s priemernou mzdou



Obr. 15: Závislosť priemernej mzdy na podieli vysokoškolských absolventov.

V grafe 15 by sa vzťah hľadal jednoduchšie ako pri grafe vzdelania 13. Pre rôzne tvrdenia o zmene v čase nemám momentálne údaje a sústredím sa na jeden rok. Je však asi celkom pochopiteľné, že za bežných okolností, čím dlhší je čas strávený v EÚ, tým viac môžu meniť štáty meniť ekonomiku na vzor vyspelejšieho jadra. Takisto sa zvyšuje aj tlak na zvyšovanie miezd, keďže práca v zahraničí už nie je taký problém.

Test nulovosti **Pearsonovho** korelačného koeficientu na hladine  $\alpha = 5\%$  zamietol ( $p = 2 \cdot 10^{-5}$ ) nekorelovanosť v prospech hypotézy, že veličiny **sú korelované**.




### 3.5 Korelačná analýza regresorov

Preskúmal som ako jednotlivé regresory spolu korelujú testom nulovosti **Pearsonových** korelačných koeficientov pre všetky dvojice regresorov. Na testovanie som využil funkciu `corr_test` z knižnice **psych**. Tá spočíta odhady Pearsonových korelačných koeficientov a  $p$ -hodnoty všetkých dvojíc regresorov. Keďže regresor **euro** je kategorický, pretypoval som ho v súlade s **one-hot encoding** na numerický.

Z výslednej matice  $p$ -hodnôt test **nezamietol hypotézy o nekorelovanosti** pre dvojice **gdp - euro** ( $p = 0.226$ ), **edu - euro** ( $p = 0.085$ ) a **edu - in\_eu** ( $p = 0.225$ ) na 5% hladine významnosti.

Z výslednej matice  $p$ -hodnôt test zamietol hypotézy o nekorelovanosti pre dvojice **gdp - edu** ( $p = 0.003$ ), **gdp - in\_eu** ( $p = 2 \cdot 10^{-4}$ ) a **euro - in\_eu** ( $p = 0.049$ ) v prospech hypotézy, že regresory **sú korelované** na 5% hladine významnosti.



Obr. 17: Pearsonove korelačné koeficienty regresorov.

Chcel som odstrániť (a aj som odstránil, viď. nižšie) regresory ktoré sú podľa grafu 17 zbytočné. Nato použijem faktor zväčšenia rozptylu **VIF**.

| Regresor | VIF   |
|----------|-------|
| gdp      | 2.678 |
| euro     | 1.338 |
| edu      | 1.714 |
| in_eu    | 2.205 |

Tabuľka 5: Hodnoty faktorov zväčšenia rozptylu (VIF).

Bežnou praxou je odstraňovať regresory, ktoré majú VIF vyššie ako 5, poprípade 10. Napriek tomu, že polovica testov napovedá problémy s kolinearitou, najvyšší odhad spomedzi korelačných koeficientov je však 0.67. Hodnota VIF, však nepracuje s dvojicami, ale snaží sa nájsť "vinníka". Pri vynechaní  $k$ -tého regresora spočíta koeficient determinácie  $R_k$ . Táto hodnota teda udáva podiel

variability vysvetlený ostatnými regresormi. No,  $1 - R_k$  potom bude časť, ktorú ostatné nevysvetľujú. Hodnota  $VIF_k = \frac{1}{1-R_k}$  teda udáva koľkokrát sa zväčší variabilita modelu ako dôsledok kolinearity  $k$ -tého regresora.

Jedno z vysvetlení prečo nemáme hodnoty nad 5 (Tabuľka 5), je to, že síce jednotlivé dvojice sú korelované, dôležité je, že nie príliš, resp. že nedokážeme nájsť regresor, ktorý by bol vyjadriteľný nejakým skalárnym súčinom vektora koeficientov a vektora zvyšných regresorov. Zjavne, každý z regresorov nesie podiel variability vysvetľovanej veličiny. Preto si dovoľím použiť **všetky regresory**.

## 4 Modely

### 4.1 Lineárny model bez interakcií

Vyskúšam jednoduchú lineárnu regresiu so všetkými vyššie vybranými regresormi bez interakcií. Formálne:

$$Y = \beta_0 + \beta_1 \cdot \text{GDP} + \beta_2 \cdot \text{euro} + \beta_3 \cdot \text{edu} + \beta_4 \cdot \text{in\_eu} + \epsilon, E\epsilon = 0$$

| Regresor  | Odhad  | $p$ -hodnota |
|-----------|--------|--------------|
| intercept | -154   | 0.729        |
| gdp       | 0.0473 | $10^{-5}$    |
| euro1     | -225   | 0.366        |
| edu       | 26.7   | 0.174        |
| in_eu     | 18.9   | 0.024        |

Tabuľka 6: Lineárny model bez interakcií.  $R_{adj}^2 = 0.865$

Nafitovaný model (Tabuľka 6) je možné interpretovať takto:


- Základný odhad v krajinách platiacich vlastnou menou je -154€.
- Za každé euro v HDP na obyvateľa sa mzda zvýši o 4.73 centov.
- Ak krajina platí eurom, základným odhadom bude  $-154 - 225 = -379$ €.
- Za každé percento obyvateľov s vysokoškolským vzdelaním pridávame 26.7€.
- Za každý rok členstva si obyvatelia prílepšia o 18.9€.

Z vyššie uvedených regresorov sú **štatisticky významné** len **HDP na obyvateľa** a **dĺžka členstva**, na hladine významnosti 5%.

Pre istotu **upozorňujem** na možnú dezinterpretáciu regresného koeficientu pre HDP na obyvateľa. Môže sa zdať, že táto hodnota je veľmi nízka, každopádne je dôležité mať na pamäti, že vysvetľovaná premenná je **mesačná** mzda a HDP na obyvateľa je za celý **rok**.


Model má pomerne vysoký adjustovaný koeficient determinácie, avšak je očividné z testov nulovosti regresných koeficientov, že najdôležitejším regresorom je HDP na obyvateľa, ktoré poskytuje dobrý odhad možno aj samo osebe. Ostatné koeficienty používa model zdá sa len na korekciu odhadov neštandardne chovajúcich sa dátových bodov vzhľadom k HDP.

Minimálne a maximálne reziduum zhruba  $\pm 1000$ € je pomerne veľké. Avšak polovica reziduí sa nachádza medzi  $\pm 300$ € čo pri takejto veľkej škále priemerných plátov je prijateľná hodnota. Očakávam teda, že budem mať nejaké odľahlé hodnoty.



Obr. 18: Vizualizácia reziduí lineárneho modelu bez interakcií.


Zo všetkých vizualizácií reziduí jednoznačne vytrča 18. krajina, ale aj s poradovým číslom 7. To sú krajiny **Luxembursko** a **Dánsko**. Luxembursko nesmie nikoho prekvapiť, je to krajina príliš malá a preto sa odlišuje od celého rádu štatistík vrámci EÚ. Dánsko je krajina s najvyššími platmi ktorá nepoužíva euro.



Obr. 19: Histogram reziduí lineárneho modelu bez interakcií.

Tak ako sa zdalo vyššie, je vidno (Obr. 19), že väčšina reziduí je pomerne blízka k nule, avšak máme aj odľahlé hodnoty.

**Shapiro** test normality na obvyklej hladine významnosti 5% nezamietol hypotézu ( $p = 0.545$ ) o normalite reziduí.



Obr. 20: Vizualizácia presnosti lineárneho modelu bez interakcií.


Z grafu 20 je vidno, že so zvyšujúcimi sa reálnymi hodnotami sa zvyšuje aj odchýlka predikcie. **Breusch - Paganov** test preto zamietol homoskedasticitu ( $p = 0.004$ ) v prospech **heteroskedasticity** na hladine 5%.

## 4.2 Lineárny model so všetkými interakciami

Model bez interakcií nespĺňal homoskedasticitu, preto som vyskúšal model so všetkými interakciami.


Dostal som čo sa reziduí týka veľmi presný model. O presnosti vypovedá aj vysoká hodnota adjustovaného koeficientu determinácie  $R^2_{\text{adj}} = 0.977$ . Avšak nemáme **ani jeden štatisticky významný** regresný koeficient. To značí o **vysokej miere kolinearitu**. To nie je prekvapením, keďže máme 16 rôznych koeficientov pre 26 dátových bodov. Model je veľmi **ťažko interpretovateľný** a pre dobro nás všetkých interpretáciu vynechávam.

V rýchlosti však zhrniem kvalitu modelu.




Obr. 21: Vizualizácia reziduí lineárneho modelu so všetkými interakciami.

Reziduá sú relatívne nízke (Obr. 21), pomerne homoskedastické.



Obr. 22: Vizualizácia presnosti lineárneho modelu so všetkými interakciami.

Ako je vidieť na grafe 22 oproti vyššiemu modelu (Obr. 20) je tento veľmi presný.



Obr. 23: Histogram reziduí lineárneho modelu so všetkými interakciami.

Pre prílišné prispôsobenie sa modelu dátam, dostávame reziduá, ktoré sú príliš sústredené okolo priemeru a hodnoty (Obr. 23), ktoré by vyššie boli ešte v poriadku sa stávajú odľahlými. Toto je dôvodom prečo **Shapiro** test normality zamietla hypotézu ( $p = 0.004$ ) o normalite reziduí na hladine významnosti 5%.

### 4.3 Výber finálneho modelu

Vyššie dve modely nám pekne ukázali extrémny všeobecne všetkých modelov. Na jednej strane máme jednoduchý ale nepresný model a na strane druhej takmer exaktne presný avšak ťažko pochopiteľný.

Skvelým nástrojom **R**, ktorý nám pomôže nájsť kompromis je **step** využívajúci ešte perfektnejší nástroj štatistiky **AIC** - *Akaikeho informačné kritérium*. Tento ukazateľ sa spočíta z vierohodnostnej funkcie odhadu regresných koeficientov a ich počtom. Pričom cieľom je nájsť najmenšiu takúto hodnotu. Funkcia **step** nato potom používa priamočiary algoritmus a to taký, že začína s prázdny modelom, predikujúcim konštantu, potom pri každej iterácii pridá regresor, alebo interakciu z už pridaných regresorov, ktorý znižuje hodnotu **AIC** najviac. Toto sa opakuje až do chvíle, keď už nie je možné pridať regresor, ktorý znižuje **AIC**.

Algoritmus dospel k modelu:

$$Y = \beta_0 + \beta_1 \cdot \text{GDP} + \beta_2 \cdot \text{in\_eu} + \beta_3 \cdot \text{euro} + \beta_4 \cdot (\text{GDP} \cdot \text{in\_eu}) + \beta_5 \cdot (\text{euro} \cdot \text{in\_eu}) + \epsilon, E\epsilon = 0$$

| Regresor    | Odhad  | <i>p</i> -hodnota    |
|-------------|--------|----------------------|
| intercept   | -564   | 0.017                |
| gdp         | 0.09   | $1.31 \cdot 10^{-7}$ |
| in_eu       | 60.9   | $3.55 \cdot 10^{-5}$ |
| euro1       | 173    | 0.522                |
| gdp:in_eu   | -0.001 | 0.001                |
| in_eu:euro1 | -24.6  | 0.062                |

Tabuľka 7: Lineárny model s najnižším AIC.  $R_{adj}^2 = 0.94$

Algoritmus teda z regresorov vylúčil vzdelanie. Výsledný model (Tabuľka 7) však obsahuje **štatisticky nevýznamný regresor meny** a jeho nevýznamnú interakciu s dĺžkou členstva, preto som odstránil ten s vyššou *p*-hodnotou a pozrel sa ako to ovplyvní model.

Formálne teda predpokladám, že:

$$Y = \beta_0 + \beta_1 \cdot \text{GDP} + \beta_2 \cdot \text{in\_eu} + \beta_3 \cdot (\text{GDP} \cdot \text{in\_eu}) + \beta_4 \cdot (\text{euro} \cdot \text{in\_eu}) + \epsilon, E\epsilon = 0$$

| Regresor    | Odhad  | <i>p</i> -hodnota    |
|-------------|--------|----------------------|
| intercept   | -515   | 0.018                |
| gdp         | 0.09   | $5 \cdot 10^{-9}$    |
| in_eu       | 57     | $8.17 \cdot 10^{-6}$ |
| gdp:in_eu   | -0.001 | 0.001                |
| in_eu:euro1 | -18    | 0.02                 |

Tabuľka 8: Finálny lineárny model.  $R_{adj}^2 = 0.942$

Tentokrát má získaný model (Tabuľka 8) všetky koeficienty regresorov **štatisticky významne odlišné od nuly** na štandardnej hladine významnosti.


#### 4.3.1 Interpretácia finálneho modelu

Nafitovaný model je možné interpretovať ako:

- Počiatočná hodnota pre štáty prijaté do EÚ v 2015 s nulovým HDP je  $-515\text{€}$ .
- Za každé euro v HDP na obyvateľa pre čerstvých členov pripisujeme  $0.094\text{€}$ .
- Za každý rok v EÚ pripočítavame  $57\text{€}$ .
- Za každý rok v EÚ sa vplyv HDP znižuje o  $0.001\text{€}$ , napr. pre 10 ročného člena pripisujeme za každé euro HDP  $0.094 - 10 \cdot 0.001 = 0.084\text{€}$ .
- Pre starších členov zjavne rast miezd vzhľadom k HDP jemne spomaľuje.
- Ak sa v krajine platí eurom, tak za každý rok členstva pripočítavme  $57 - 18 = 39\text{€}$ . Pre krajiny platiace eurom sa rast miezd vzhľadom k dĺžke členstva spomaľuje.


#### 4.3.2 Analýza reziduí finálneho modelu

Preskúvam reziduá modelu.



Obr. 24: Vizualizácia reziduí finálneho modelu.

Je možné vidieť z grafu 24, že **Luxembursko** a **Dánsko** sú opäť odľahlými pozorovaniami.




Obr. 25: Vizualizácia reziduí finálneho modelu.

Na grafe 25 to vyzerá pomerne sľubne, je symetrický okolo nuly, ale pomerne málo bodov je blízko priemeru.

**Shapiro** test nezamietol ( $p = 0.303$ ) **normalitu reziduí** na bežnej hladine významnosti.

**Breschov - Paganov** test nezamieta ( $p = 0.773$ ) **homoskedasticitu** na bežnej hladine významnosti.

#### 4.3.3 Vizualizácia finálneho modelu



Obr. 26: Vizualizácia presnosti finálneho modelu.

Model vyzerá (Obr. 26) byť o čosi nepresnejší ako komplikovaný s interakciami. Je ale vidno zlepšenie oproti jednoduchému modelu bez interakcií (Obr. 20). Hlavne čo sa týka variability modelu v závislosti

na hodnote vysvetľovanej premennej.

#### 4.3.4 Redukcia modelu s najnižším AIC skóre a so všetkými interakciami

Následne som sa pozrel, či je možné bez väčšej straty na presnosti redukovať pôvodný model so všetkými interakciami na najnižší s AIC skóre a na model po odobratí eura (finálny).

Testy som previedol  $\chi^2$  aj F testom. Oba testy dospeli k záveru, že **odobratie eura** ( $p_{\chi^2} = 0.298, p_F = 0.322$ ) z modelu s najnižším AIC **nespôsobí štatisticky významnú stratu presnosti**. Testy sa taktiež zhodli, že **model so všetkými interakciami nie je možné zredukovať** bez straty na presnosti ( $p_{\chi^2} = 10^{-5}, p_F = 0.018$ ). Keďže trpel vysokou kolinearitou a ani nemal normálne rozdelené reziduá, vyberám ako finálny model ten posledný.

## 5 Záver

Podarilo sa pochopiť štruktúru priemerných mesačnov platov krajín EÚ. Mohli sme, okrem iného, byť svedkami **veľkých rozdielov finančného ohodnotenia** v skúmaných krajinách.

Taktiež sme zistili, že **dominantne mzdu ovplyvňuje HDP na obyvateľa**, ktorému ochotne asistujú dĺžka členstva v Únii a jemne aj vplyv eura. Všetko nasvedčuje tomu, že čím dlhšie je krajina členom, tým viac sa zoslabuje vplyv HDP na mzdu. Takisto po prijatí eura krajina ťaží menej z doby keď je členom.

Zdá sa, že podiel absolventov **vysokých škôl nemá výrazný vplyv** na priemernú mzdu. Čo je možné pripísať rozdielnej kvalite vzdelávania naprieč krajinami. **Nevýrazný vplyv eura** taktiež môže mnohých prekvapiť. Ukazuje sa, že euro nepoužívajú výrazne platovo nadpriemerné alebo podpriemerné krajiny, čo sa týka priemeru za celú EÚ.

Mohli sme **experimentovať s rôznymi modelmi**, od príliš jednoduchého po veľmi komplexný. Našli sme však zlatú strednú cestu, ktorá je relatívne ľahko interpretovateľná a pochopiteľná a zároveň dostatočne presná.