

Analýza priemerných miezd v štátoch Európskej únie

Tomáš Becza

Máj 2025

1 Úvod

Jedným z najdôležitejších ukazateľov (aj keď nie jediným) kvality života v rôznych štátoch je nesporne priemerná mesačná mzda. V tejto práci sa zamerám na jej analýzu vo vybraných štátoch Európskej únie v roku 2015.

Hlavnými cieľmi práce sú odpovedať na nasledujúce otázky:

- Aké hodnoty má sledovaná veličina? Aká je priemerná mzda naprieč EÚ? Ktoré štáty najviac vyčnievajú?
- Aké iné veličiny ovplyvňujú mzdu? Ktoré z nich majú najväčší dopad?
- Ako je možné z daných veličín aproximovať reálnu hodnotu priemernej mzdy? Je daný vzťah spoľahlivý?

2 Priemerná mzda

Hodnoty priemernej mzdy získam z Eurostatu, konkrétne z datasetu `*nama10fte*`

*.Tenobsahujedátaz26krajínEÚ, vskúmanomroku2015všakchýba *Spojenékráľovstvo*, ktorévtedyesteboľosú*

Dataset takisto obsahuje priemernú mzdu `**EU27_2020**`, ktorájepre27krajínsúčasnehozloženiaEÚ(vrátane

Menou, v ktorej budem skúmať mzdy, bude euro. A keďže nie sme zvyknutý na ročnú mzdu, pre lepšie predstavenie ju prevediem na mesačnú.

2.1 Charakteristika

Pozrieme sa bližšie na významné štatistické miery.

```
“r sumn j- c('notNA(x)', 'mean(x)', 'sd(x)', 'min(x)', 'pctile(x)[25]', 'median(x)', 'pctile(x)[75]', 'max(x)', 'IQR(x)') sumtable(data.frame(salary=salary), out = "return", summ = summ)“
```

Vidíme, že skutočne máme 26 štátov, s najmenšou priemernou mzdou 531€ a najvyššou 5116€. Čo je takmer desaťnásobok, môžeme teda očakávať že mzdy budú veľmi rozptýlené, čo dosvedčuje aj vysoká smerodatná odchýlka. Ďalej je

možné vidieť, že aj priemer týchto priemerov je vyšší ako medián, čo znamená, že máme málo veľmi bohatých štátov.

```
“r par(mfrow = c(1, 2)) hist(salarysalary, main = "", xlab = 'Wage [EUR]', ylab = 'Frequency', col = 'lightblue') boxplot(salarysalary, ylab = 'Wage [EUR]', col = 'lightblue') mtext('Average monthly wage in EU countries', outer = TRUE, cex = 1.75, line = -2.5) “
```

Na histograme vidíme, akoby bola Únia rozdelená na chudobnejšiu (1000 - 2000€) a bohatšiu (3000 - 4000€) časť. Samozrejme je vidieť aj 3 štáty ktoré sú medzi týmito skupinami. Máme aj veľmi chudobné štáty (na európske pomery), ktoré majú priemernú mzdu pod 1000€, ale aj veľmi bohaté štáty nad 4000€.

```
“r par(mar=c(6,5,4,1)) data_with_cat = rbind(salary, salary_eu) data_with_catcat = grepl('2', data_with_catgeo) data_with_catcat = as.character(data_with_catcat) data_with_cat = data_with_cat[order(data_with_catcat, decreasing = TRUE),] data_with_catcat = ifelse(data_with_catcat, 'lightblue', 'yellow') barplot(data_with_catcat, names.arg = data_with_catgeo, ylab = 'Wage [EUR]', col = data_with_catcat, las= 2) mtext('Average monthly wage in EU countries', outer = TRUE, cex = 1.75, line = -2.5) “
```

Rebríček najvyšších miezd neprekvapivo otvára *Luxembursko* nasledované *Dánskom* a *Írskom*. Najnižšie mzdy sú v *Bulharsku* a *Rumunsku*. Ďalej je možné vidieť, že priemerná mzda v eurozóne je vyššia ako v celej EÚ súhrne. Najväčšie krajiny EÚ ako *Nemecko*, *Francúzsko* a *Taliansko* ovplyvňujú celkovú priemernú mzdu výraznejšie ako ostatné štáty a teda sú aj blízko priemeru za EÚ.

2.2 Faktory ovplyvňujúce priemernú mzdu

Existuje množstvo údajov, ktoré majú dané štáty odlišné. Chceme sa však zamerať na také ukazatele, ktoré by mohli mať vplyv na priemernú mzdu v štáte.

HDP na obyvateľa môže hrať snáď najdôležitejšiu rolu. Veľmi dôležitý ukazateľ, ktorý sa často globálne používa aj sám osebe ako numerickým vyjadrením kvality krajiny. Asi je pomerne intuitívny nápad, že kde je viac peňazí, tam sa aj viac ujde jednotlivcovi.

Z vyššieho grafu je vidno napríklad, že z prvých troch krajín používajú **euro** dve, z posledných ani jedna. Navyše priemer eurozóny je vyšší ako celej EÚ, teda je logické uvažovať aj tento vplyv. Na prijatie do eurozóny je potrebné splniť prísne ekonomické podmienky, čo teda môže znamenať, že krajine sa ekonomicky darí, tým pádom môže byť predpoklad na vyššiu mzdu oprávnený.

Veľmi často sa stretávame aj s tvrdeniami, že titul z **vysokej školy** zabezpečí osobe nadpriemerný príjem. Preto má zmysel uvažovať podiel absolventov týchto škôl v populácii krajiny. Títo absolventi sú schopní vykonávať práce s vysokými požiadavkami na znalosti, ktoré sú aspoň do istej miery odmenené.

Pozorné oko si v grafe vyššie všimne, že všetky krajiny nad európskym priemerom sa **pripojili k EÚ** ešte v minulom storočí (dokonca tisícročí). Na

vstup do EÚ je potrebné tiež splniť radu požiadaviek. Členstvo v EÚ poskytuje priaznivé prostredie pre obchod a celkovo legislatívny aparát podporujúci rast miezd. Netreba zabudnúť ani na eurofondy, ktoré krajina čerpá aj na podporu zamestnania.

3 Regresory

3.1 HDP na obyvateľa

Dáta získam z Eurostatu, konkrétne z `*tipsna40*`. Dataset obsahuje údaje o hodnote HDP na obyvateľa vo vybraných európskych krajinách. Ja sa zameriam na rok 2015 a krajiny v ktorých mám priemernú mzdu.

3.1.1 Charakteristika

```
“r summ j- c('notNA(x)', 'mean(x)', 'sd(x)', 'min(x)', 'pctile(x)[25]', 'median(x)',
'pctile(x)[75]', 'max(x)', 'IQR(x)') sumtable(data.frame(gdp_gdp), out = "return", summ =
summ)“
```

Je vidno obrovský rozdiel medzi priemerom a mediánom, preto očakávam, že tu bude zopár skutočne odľahlých hodnôt.

```
“r par(mfrow = c(1, 2)) hist(gdp_gdp, main = "", xlab = 'GDPpercapita[EUR/capita]', ylab =
'Frequency', col = 'lightblue') boxplot(gdp_gdp, ylab = 'GDP per capita [EUR/capita]',
col = 'lightblue') mtext('GDP per capita', outer = TRUE, cex = 1.75, line =
-2.5) “
```

Na grafe je vidno, že veľká väčšina krajín má HDP na obyvateľa do 40 tisíc eur. Nad touto hranicou sa nachádzajú už len štyri krajiny.

```
“r par(mar=c(6,5,4,1)) data_with_cat = rbind(gdp, gdp_eu) data_with_catcat =
grepl('2', data_with_catgeo) data_with_catcat = as.character(data_with_catcat) data_with_cat =
data_with_cat[order(data_with_catgdp, decreasing = TRUE),]
data_with_catcat = ifelse(data_with_catcat, 'lightblue', 'yellow')
barplot(data_with_catgdp, names.arg = data_with_catgeo, ylab = 'GDP per
capita [EUR/capita]', col = data_with_catcat, las= 2, cex.axis = 0.7) mtext('GDP
per capita in EU countries', outer = TRUE, cex = 1.75, line = -2.5) “
```

Máme možnosť vidieť takmer identický graf ako graf priemerných mesačných miezd. Výrazným rozdielom je ešte vytŕčajúce *Luxembursko*, ktoré to dosahuje hlavne kvôli svojej malej populácii.

3.1.2 Vzťah s priemernou mzdou

```
“r data = merge(gdp, salary) data_eu = merge(gdp_eu, salary_eu) plot(data_gdp,
datasalary, col = 'blue', pch = 16, main = 'GDP and average wage in EU', xlab =
'GDPpercapita[EUR/capita]', ylab = 'Averagemonthlywage[EUR]') points(data_eu_gdp,
data_eu_salary, col=c('yellow', 'orange'), pch=16) legend('bottomright', legend =
c('EU member states', 'Eurozone mean', 'EU mean'), col = c('blue', 'yellow',
'orange'), pch = 16) “
```

Až na zopár bodov, je vidno, že medzi veličinami je takmer dokonalý lineárny vzťah. Pozrime sa preto na Pearsonov korelačný koeficient a otestujme.

$$H_0 : \rho = 0$$

$$H_A : \rho \neq 0$$

```
“r cor.test(data$gdp, data$salary, method = 'pearson') “
```

Na hladine $\alpha = 5\%$ zamietam H_0 v prospech hypotézy, že veličiny sú korelované.

3.2 Členstvo v eurozóne

Dáta získam z verejne dostupných informácií a uložíam do jednoduchého dataframe-u.

```
“r eurozone_member = data.frame(geo = countries2015[grep('2', countries2015)], euro = c(1, 1, 0, 1, 0, 1, 0, 1, 1, 1, 1, 1, 0, 0, 1, 1, 1, 1, 1, 1, 0, 1, 0, 0, 1, 1))
eurozone_member$geo = as.factor(eurozone_member$geo)
eurozone_member$euro = as.factor(eurozone_member$euro)
data = merge(data, eurozone_member)“
```

3.2.1 Charakteristika a vplyv na platy

```
“r par(mfrow = c(1, 2))
factor je cislovany od 1 with_euro = sum(as.integer(data$euro) - 1)
pie(c(with_euro, length(data$euro) - with_euro), labels = c(paste0('Euro(', with_euro, ')'), paste0('National currency', with_euro, ')')), init.angle = 180, col = c('lightblue', 'yellow'), cex = 0.9)
boxplot(data$salary ~ data$euro, col = c('yellow', 'lightblue'), ylab = 'Average monthly wage [EUR]', xlab = "", names = c('National currency', 'Euro')) “
```

Ako môžeme vidieť, zo sledovaných štátov platia viac ako dve tretiny eurom. Takisto je vidno, že priemerný plat v štátoch platiacich eurom je okolo tisícky vyšší ako kde platia vlastnou menou. Napriek malému počtu krajín používajúcich národnú menu, je rozptyl hodnôt takmer rovnaký ako s dvakrát početnejšou skupinou používajúcich euro.

```
“r par(mar=c(6,5,5,1))
salary_euro = NA
data_with_cat = rbind(data[c('geo', 'salary', 'euro')], salary_euro)
data_with_cat = data_with_cat[order(data_with_cat$salary, decreasing = TRUE),]
data_with_cat$cat = ifelse(is.na(data_with_cat$euro), 'gray', ifelse(data_with_cat$euro == 1, 'lightblue', 'yellow'))
barplot(data_with_cat$salary, names.arg = data_with_cat$geo, ylab = 'Average wage per month [EUR]', col = data_with_cat$cat, las=2, cex.axis=0.7)
mtext('Average wages by euro usage', outer = TRUE, cex = 1.75, line = -2.5)
legend('topright', legend = c('Euro', 'National currency', 'Not relevant'), col = c('lightblue', 'yellow', 'gray'), pch = 16) “
```

Z grafu je očividné, kde sa berie vysoká variácia pre štáty platiace národnou menou. Môžeme v tejto skupine nájsť dve vysoko nadpriemerné štáty, čo sa platov týka, *Dánsko*, ktoré má z povinnosti prijať euro výnimku a *Švédsko*. Ostatné štáty nepoužívajúce euro majú platy nižšie ako polovica z priemeru eurozóny. Tam je však možné nájsť aj nenulový počet krajín s eurom.

Podme teda otestovať vplyv eura na strednú hodnotu mesačných plátov.

H_0 : Stredná hodnota mesačných plátov nezávisí na používaní eura.

H_A : neplatí H_0 .

```
“r anova(aov(datasalary dataeuro)) “
```

Nezamietam hypotézu H_0 na hladine významnosti 5%.

3.3 Vysoké školy

Dáta sú z Eurostatu a ide o dataset `*edat_lfse03*.Datasetobsahujemnohoúdajovoabsolventochškôlveurópskych`

Ďalej ma budú zaujímať len absolventi týchto úrovní vzdelania podľa štandardu

ISCED 2011:

* úroveň 5 - krátkodobé úspešne ukončené vysokoškolské vzdelanie, * úroveň 6 - bakalárske vzdelanie, * úroveň 7 - magisterské vzdelanie, * úroveň 8 - doktorandské vzdelanie,

spolu združené v kategórii *ED5-8*.

3.3.1 Charakteristika

```
“r summ j- c('notNA(x)', 'mean(x)', 'sd(x)', 'min(x)', 'pctile(x)[25]', 'median(x)',  
'pctile(x)[75]', 'max(x)', 'IQR(x)') sumtable(data.frame(eduedu), out = "return", summ =  
summ)“
```

Podiel absolventov vysokých škôl je zatiaľ najviac vyrovnaným ukazovateľom v EÚ. Priemer medzi krajinami by sme našli presne kde medián - na hodnote 27. Polovica krajín má vysokoškolskú vzdelanosť na úrovni medzi 21 a 33 percent.

```
“r par(mfrow = c(1, 2)) hist(eduedu, main = "", xlab = 'Tertiary education[boxplot(eduedu,  
ylab = 'Tertiary education [ mtext('Tertiary education', outer = TRUE, cex =  
1.75, line = -2.5) “
```

Tak ako vyššie čísla naznačovali, skutočne dáta vyzerajú takmer ako z rovnomerného rozdelenia.

```
“r par(mar=c(6,5,4,1)) data_with_cat = rbind(edu, edu_eu) data_with_catcat =  
grepl('2', data_with_catgeo) data_with_catcat = as.character(data_with_catcat) data_with_cat =  
data_with_cat[order(data_with_catedu, decreasing = TRUE),]
```

```
data_with_catcat = ifelse(data_with_catcat, 'lightblue', 'yellow')
```

```
barplot(data_with_catedu, names.arg = data_with_catgeo, ylab = 'Tertiary edu-  
cation [ col = data_with_catcat, las= 2, cex.axis = 0.7) mtext('Tertiary education  
in EU countries', outer = TRUE, cex = 1.75, line = -2.5) “
```

Najvyššie úrovne vysokoškolského vzdelania sú v *Írsku*, na *Cypre* a vo *Fínsku*. Írske a fínske školy sú celosvetovo známe pre svoju kvalitu, preto nie je prekvapením, že miestni vidia možno väčší zmysel v štúdiu ako priemerný občan EÚ. Cyprus je prekvapivým štátom, vysoký podiel môže byť zapríčinený blízkym ľudnatým Tureckom a všeobecne je najbližším EÚ štátom aj pre Blízky východ a časť Afriky. Týchto ľudí z okolia možno láka geografická blízkosť a vidina uznávaného titulu z členského štátu EÚ. Táto krajina je tiež známa nízkou daňovou záťažou a preto má veľa firiem (formálne) sídlo pre EÚ práve tu. No a je všeobecne známe, že korporáty si potrpia na vzdelanie.

Najnižšie môžeme nájsť v *Rumunsku*, *Taliansku* a na *Slovensku*. Rumunsko a Slovensko sú určite krajiny, ktoré trpia "odlivom mozgov". Ťažko nájsť dôvod prečo sa však nedarí Taliansku. Môže byť, že v krajine sa nie je veľký problém zamestnať bez vysokej školy a tak nie je veľmi populárnou voľbou. Je tiež známe, že napriek veľmi rozvinutému severu krajiny, na juhu možnosti zďaleka nie sú rovnaké, tento rozdiel v regiónoch sa možno práve v tejto štatistike odzrkadľuje.

3.3.2 Vzťah s priemernou mzdou

```
“r data = merge(data, edu) data_eu = merge(data_eu, edu_eu) plot(dataedu, datasalary, col = 'blue', pch = 16, main = 'Tertiary education and average wage in EU', xlab = 'Tertiary education [points]', ylab = 'Average monthly wage [EUR]', col = c('yellow', 'orange'), pch = 16) legend('topleft', legend = c('EU member states', 'Eurozone mean', 'EU mean'), col = c('blue', 'yellow', 'orange'), pch = 16) “
```

Preložiť tieto body nejakou priamkou asi veľmi zmysel nedáva. Minimálne však je vidno, že väčšinou s úrovňou vysokoškolského vzdelania rastie aj priemerný plat.

Podme si koreláciu otestovať testom nulovosti *Pearsonovho* korelačného koeficientu.

$$H_0 : \rho = 0$$

$$H_A : \rho \neq 0$$

```
“r cor.test(dataedu, datasalary, method = 'pearson') “ Na hladine  $\alpha = 5\%$  zamietam  $H_0$  v prospech hypotézy, že veličiny sú korelované.
```

3.4 Dĺžka členstva v EÚ

Údaje o dĺžke členstva som získal z verejne dostupných zdrojov.

3.4.1 Charakteristika

```
“r summ_j = c('notNA(x)', 'mean(x)', 'sd(x)', 'min(x)', 'pctile(x)[25]', 'median(x)', 'pctile(x)[75]', 'max(x)', 'IQR(x)') sumtable(data.frame(datain_eu), out = "return", summ = summ) “
```

Najstarší členovia (zakladajúci) sú v Únii už 57 rokov (od 1958). Najmladšie *Chorvátsko* sa pripojilo pred dvomi rokmi. Časovým obdobím, ktoré rozdeľuje Úniu na (takmer) rovnako veľké dve časti starých a nových členov je 16 rokov.

3.4.2 Vzťah s priemernou mzdou

```
“r plot(datain_eu, datasalary, col = 'blue', pch = 16, main = 'Length of EU membership and average monthly wage', xlab = 'Length of membership [ years ]', ylab = 'Average monthly wage [EUR]') “
```

Tu by sa vzťah hľadal jednoduchšie ako pri vzdelaní. Pre rôzne tvrdenia o zmene v čase nemám momentálne údaje a sústredím sa na jeden rok. Je však asi celkom pochopiteľné, že za bežných okolností, čím dlhší je čas strávený v EÚ, tým viac môžu štáty meniť ekonomiku na vzor vyspelejšieho jadra.

Takisto sa zvyšuje aj tlak na zvyšovanie miezd, keďže práca v zahraničí už nie je taký problém.

Tvrdenia podporím testom nulovosti *Pearsonovho* korelačného koeficientu.

$$H_0 : \rho = 0$$

$$H_A : \rho \neq 0$$

“r cor.test(data_{in_eu}, data_{salary}, method = 'pearson') “

Na hladine $\alpha = 5\%$ zamietam H_0 v prospech hypotézy, že veličiny sú korelované.

Korelačná analýza regresorov

Overme ako jednotlivé regresory spolu korelujú testom nulovosti *Pearsonových* korelačných koeficientov. Máme teda hypotézy:

$$H_{0;i,j} : \rho_{i,j} = 0$$

$$H_{A;i,j} : \rho_{i,j} \neq 0$$

kde $i, j \in \{HDP, vzdelanie, euro, dĺžkačlenstva\}$.

Na testovanie využijem funkciu *corr_{test}*z knižnice 'psych'. Tá spočíta odhad $\rho_{i,j}$ a p -hodnoty všetkých dvojíc regresorov. Keďže regresor *euro* je kategorický, pretypujem ho v súlade s *one-hot encoding* na numerický.

“r data_{for_{corr_{test}}} = data[c('gdp', 'edu', 'euro', 'in_eu')]data_{for_{corr_{test}}}euro = as.integer(data_{for_{corr_{test}}}euro) - 1

res = corr.test(data_{for_{corr_{test}}}, method = "pearson", adjust = "none")

resr

resp“

Z výslednej matice p -hodnôt nezamietam hypotézy o nekorelovanosti pre dvojice **gdp - euro**, **edu - euro** a **edu - in_eu** na 5% hladine významnosti.

Z výslednej matice p -hodnôt zamietam hypotézy o nekorelovanosti pre dvojice **gdp - edu**, **gdp - in_eu** a **euro - in_eu** v prospech hypotézy, že regresory sú korelované na 5% hladine významnosti.

“r corplot(resr, method = 'square')“

Podme teda odstrániť regresory ktoré sú zbytočné. Nato použijem faktor zvážšenia rozptylu **VIF**.

“r data.frame(vif(lm(salary ~ gdp + euro + edu + in_eu, data = data)))“

Bežnou praxou je odstraňovať regresory, ktoré majú VIF vyššie ako 5, poprípade 10. Napriek tomu, že polovica testov napovedá problémy s kolinearitou, najvyšší odhad spomedzi korelačných koeficientov je však 0.67. Hodnota VIF, však nepracuje s dvojicami, ale snaží sa nájsť "vinníka". Pri vynechaní k -tého regresora spočíta koeficient determinácie R_k . Táto hodnota teda udáva podiel variability vysvetlený ostatnými regresormi. No, $1 - R_k$ potom bude časť, ktorú ostatné nevysvetľujú. Hodnota $VIF_k = \frac{1}{1 - R_k}$ teda udáva koľkokrát sa zvážši variabilita modelu ako dôsledok kolinearity k -tého regresora.

Jedno z vysvetlení prečo nemáme hodnoty nad 5, je to, že síce jednotlivé dvojice sú korelované, dôležité je, že nie príliš, resp. že nedokážeme nájsť regresor, ktorý by bol vyjadriteľný nejakým skalárnym súčinom vektora koeficientov a vektora zvyšných regresorov. Zjavne, každý z regresorov nesie podiel variability vysvetľovanej veličiny. Preto si dovoľm použiť všetky regresory.

4 Modely

4.1 Lineárny model bez interakcií

Vyskúšam jednoduchú lineárnu regresiu so všetkými vyššie vybranými regresormi bez interakcií. Formálne:

$$Y = \beta_0 + \beta_1 \cdot GDP + \beta_2 \cdot euro + \beta_3 \cdot in_eu + \beta_4 \cdot in_eu + \epsilon, E\epsilon = 0$$

```
“r fit_all = lm(salary~gdp+euro+edu+in_eu, data = data)summary(fit_all)“
```

Model je možné interpretovať takto:

* Základný odhad v krajinách platiacich vlastnou menou je -153€ . * Za každé euro v HDP na obyvateľa sa mzda zvýši o 4.7 centov. * Ak krajina platí eurom, zo mzdy strhávame 225€. * Za každé percento obyvateľov s vysokoškolským vzdelaním pridávame 27€. * Za každý rok členstva si obyvateľia prilepšia o 19€.

Z vyššie uvedených regresorov sú štatisticky významné len HDP na obyvateľa a dĺžka členstva, na hladine významnosti 5%.

Pre istotu upozorňujem na možnú dezinterpretáciu regresného koeficientu pre HDP na obyvateľa. Môže sa zdať, že táto hodnota je veľmi nízka, každopádne je dôležité mať na pamäti, že vysvetľovaná premenná je **mesačná** mzda a HDP na obyvateľa je za celý **rok**.

Model má pomerne vysoký adjustovaný koeficient determinácie, avšak je očividné z p -hodnôt testov nulovosti regresných koeficientov, že najdôležitejším regresorom je HDP na obyvateľa, ktoré poskytuje dobrý odhad možno aj samo osebe. Ostatné koeficienty používa model zdá sa len na korekciu odhadov neštandardne chovajúcich sa dátových bodov vzhľadom k HDP.

Minimálne a maximálne reziduum zhruba $\pm 1000\text{€}$ je pomerne veľké. Avšak polovica reziduí sa nachádza medzi $\pm 300\text{€}$ čo pri takejto veľkej škále priemerných platov je prijateľná hodnota. Očakávam teda, že budem mať nejaké odľahlé hodnoty.

```
“r par(mfrow=c(2, 2)) plot(fit_all, which = c(1, 2, 3, 4))“
```

Zo všetkých vizualizácií reziduí jednoznačne vytŕča 18. krajina, ale aj s poradovým číslom 7.

```
“r as.character(data[c(18, 7),]geo)“
```

Vidíme, že sú nimi krajiny **Luxembursko** a **Dánsko**. Luxembursko nesmie nikoho prekvapiť, je to krajina príliš malá a preto sa odlišuje od celého rádu štatistik vrámci EÚ. Dánsko je krajina s najvyššími platmi ktorá nepoužíva euro.

Pozriem sa teraz na normalitu reziduí.

```
“r hist(fit_all$residuals, col = 'lightblue', xlab='Residuals', main='Histogram of residuals’) “
```

Tak ako sa zdalo vyššie, je vidno, že väčšina reziduí je pomerne blízka k nule, avšak máme aj odľahlé hodnoty. Poďme sa pozrieť, či to ešte splní podmienky normality.

H_0 : Reziduá pochádzajú z normálneho rozdelenia.

H_A : Neplatí H_0 .

```
“r shapiro.test(fit_all$residuals) “
```

Na obvyklej hladine významnosti 5% nezamietam hypotézu o normalite reziduí.

Teraz si vizualizujem ako sa predikcia modelu líši od reálnych hodnôt.

```
“r pred = predict.lm(fit_all, data)plot(datasalary, pred, xlim = c(500, 6500),  
ylim = c(500, 6500), pch = 16, col = 'blue', xlab = 'True', ylab = 'Prediction',  
main='Average monthly wage') abline(a=0, b=1, lwd = 2, col='red') “
```

Je vidno, že so zvyšujúcimi sa reálnymi hodnotami sa zvyšuje aj odchýlka predikcie. Poďme to otestovať *Breuschovým - Paganovým* testom.

H_0 : Model je homoskedasticitný.

H_A : Model je heteroskedasticitný.

```
“r bptest(fit_all) “
```

Zamietam H_0 v prospech heteroskedasticity na hladine 5%.

4.2 Lineárny model s interakciami

Model bez interakcií nespĺňal homoskedasticitu, preto vyskúšam model so všetkými interakciami.

```
“r fit_all_int = lm(salary gdp*edu*ineuro, data = data)summary(fit_all_int) “
```

Dostávame čo sa reziduí týka veľmi presný model. O presnosti vypovedá aj vysoká hodnota adjustovaného koeficientu determinácie. Avšak nemáme ani jeden štatisticky významný regresný koeficient. To značí o vysokej miere kolinearity. To nie je prekvapením, keďže máme 16 rôznych koeficientov pre 26 dátových bodov. Model je veľmi ťažko interpretovateľný a pre dobro nás všetkých interpretáciu vynechávam.

V rýchlosti však zhrniem kvalitu modelu.

```
“r warning = FALSE par(mfrow=c(2, 2)) plot(fit_all_int, which = c(1, 2, 3, 4)) “
```

Reziduá sú relatívne nízke, pomerne homoskedastické.

```
“r pred = predict.lm(fit_all_int, data)plot(datasalary, pred, xlim = c(500,  
6500), ylim = c(500, 6500), pch = 16, col = 'blue', xlab = 'True', ylab = 'Pre-  
diction', main='Average monthly wage') abline(a=0, b=1, lwd = 2, col='red')  
“
```

Oproti vyššiemu modelu je tento veľmi presný.

```
“r hist(fit_all_int$residuals, col = 'lightblue', xlab='Residuals', main='Histogram  
of residuals') “
```

Pre prílišné prispôsobenie sa modelu dátam, dostávame reziduá, ktoré sú príliš sústredené okolo priemeru a hodnoty, ktoré by vyššie boli ešte v poriadku sa stávajú odľahlými. Otestujme to.

H_0 : Reziduá pochádzajú z normálneho rozdelenia.

H_A : Neplatí H_0 .

```
“r shapiro.test(fit_all_int$residuals) “
```

Skutočne zamietam hypotézu o normalite reziduí na hladine významnosti 5%.

4.3 Výber finálneho modelu

Vyššie dve modely nám pekne ukázali extrémny všeobecne všetkých modelov. Na jednej strane máme jednoduchý ale nepresný model a na strane druhej takmer exaktne presný avšak ťažko pochopiteľný.

Skvelým nástrojom 'R', ktorý nám pomôže nájsť kompromis je 'step' využívajúci ešte perfektnejší nástroj štatistiky 'AIC' - Akaikeho informačné kritérium. Tento ukazateľ sa spočíta z vierohodnostnej funkcie odhadu regresných koeficientov a ich počtom. Pričom cieľom je nájsť najmenšiu takúto hodnotu. Funkcia 'step' nato potom používa priamočiary algoritmus a to taký, že začína s prázdny modelom, predikujúcim konštantu, potom pri každej iterácii pridá regresor, alebo interakciu z už pridaných regresorov, ktorý znižuje hodnotu 'AIC' najviac. Toto sa opakuje až do chvíle, keď už nie je možné pridať regresor, ktorý znižuje 'AIC'.

```
“r step(lm(datasalary 1), scope = list(lower = 1, upper = datagdp *
dataedu*datainu*dataeuro)) “ “r fit_lowest_aic = lm(formula = salary gdp+
inu + euro + gdp : inu + inu : euro, data = data)summary(fit_lowest_aic)“
```

Algoritmus nám teda z regresorov vylúčil vzdelanie. Výsledný model však obsahuje štatisticky nevýznamný regresor meny, preto ho odstránim a pozriem sa ako to ovplyvní model.

Formálne teda budem predpokladať, že:

$$Y = \beta_0 + \beta_1 \cdot GDP + \beta_2 \cdot in_eu + \beta_3 \cdot (GDP \cdot in_eu) + \beta_4 \cdot (euro \cdot in_eu) + \epsilon, E\epsilon = 0$$

```
“r fit_fin = lm(formula = salary gdp+inu+gdp : inu+inu : euro, data =
data)summary(fit_fin)“
```

Je vidno, že získaný model má všetky koeficienty regresorov štatisticky významne odlišné od nuly na štandardnej hladine významnosti.

Interpretácia Tento model je možné interpretovať ako:

* Počiatočná hodnota pre štáty prijaté do EÚ v 2015 s nulovým HDP je -515€. * Za každé euro v HDP na obyvateľa pre čerstvých členov pripisujeme 0.094€. * Za každý rok v EÚ pripočítavame 57€. * Za každý rok v EÚ sa vplyv HDP znižuje o 0.001€, napr. pre 10 ročného člena pripisujeme za každé euro HDP $0.094 - 10 \cdot 0.001 = 0.084$ €. Pre starších členov zjavne rast miezd vzhľadom k HDP jemne spomaľuje. * Ak sa v krajine platí eurom, tak za každý rok členstva pripočítavme $57 - 18 = 39$ €. Pre krajiny platiace eurom sa rast miezd vzhľadom k dĺžke členstva spomaľuje.

4.3.1 Analýza reziduí

Podme sa pozrieť na reziduá modelu.

```
“r par(mfrow=c(2, 2)) plot(fit_fin, which = c(1, 2, 3, 4))“
```

Je možné vidieť, že *Luxembursko* a *Dánsko* sú opäť odľahlými bodmi.

```
“r hist(fit_fin$residuals, col = 'lightblue', xlab='Residuals', main='Histogram
of residuals')“
```

Na grafe to vyzerá pomerne sľubne, je symetrický okolo nuly, ale pomerne málo bodov je blízko priemeru.

H_0 : Reziduá pochádzajú z normálneho rozdelenia.

H_A : Neplatí H_0 .

```
“r shapiro.test(fitfinresiduals) “
```

Nezamietam normalitu reziduí na bežnej hladine významnosti.

Breschovým - Paganovým testom overím homoskedasticitu.

H_0 : Model je homoskedasticitný.

H_A : Model je heteroskedasticitný.

```
“r bptest(fitfin) “
```

Nezamietam homoskedasticitu na bežnej hladine významnosti.

4.3.2 Vizualizácia modelu

```
“r pred = predict.lm(fitfin, data)plot(datasalary, pred, xlim = c(500, 6500),  
ylim = c(500, 6500), pch = 16, col = 'blue', xlab = 'True', ylab = 'Prediction',  
main='Average monthly wage') abline(a=0, b=1, lwd = 2, col='red') “
```

Model vyzerá byť o čosi nepresnejší ako komplikovaný s interakciami. Je ale vidno zlepšenie oproti jednoduchému modelu bez interakcií. Hlavne čo sa týka variability modelu v závislosti na hodnote vysvetľovanej premennej.

4.3.3 Test redukcie modelu

Následne sa pozriem, či je možné bez väčšej straty na presnosti redukovať pôvodný model so všetkými interakciami na najnižší s AIC skóre a na model po odobratí eura. Testy prevediem χ^2 aj F testom.

```
“r anova(fitfin, fitlowest_aic, fitall_int, test = 'Chisq') “
```

```
“r anova(fitfin, fitlowest_aic, fitall_int, test = 'F') “
```

Obe testy dospeli k záveru, že odobratím eura z modelu s najnižším AIC nespôsobí štatisticky významnú stratu presnosti. Takisto však vidíme, že obe model so všetkými interakciami nie je možné zredukovať bez straty na presnosti. Keďže trpel vysokou kolinearitou a ani nemal normálne rozdelené reziduá, vyberám ako finálny model ten posledný.